ФИО	Группа	Работа
Пластинин Алексей Александрович	37	ISA

C++20 g++

Теория:

Структура ELF файла (источник 4 страница 15) здесь и далее страница указана от начала файла, а не по существующей нумерации:

Figure 1-1. Object File Format

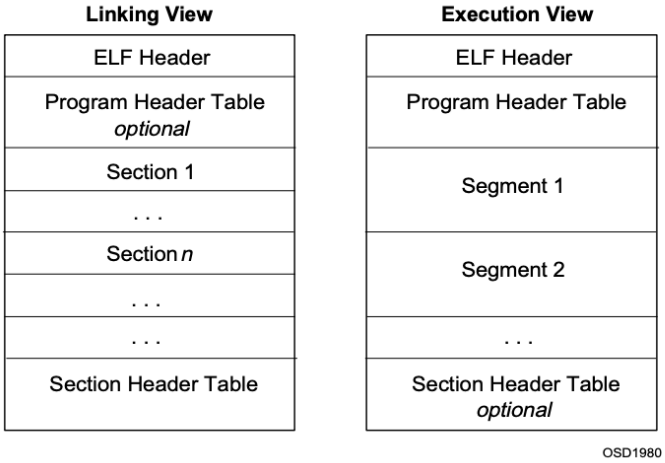

Далее будем опираться на Linked View. ELF Header содержит информацию о организации файла. Section Header Table содержит информацию о секциях в файле. Секции содержат информацию необходимую для сборки и исполнения программы.

Структура ELF Header (источник 4 страница 18):

Figure 1-3. ELF Header

```
#define EI_NIDENT       16

typedef struct {
          unsigned char  e_ident[EI_NIDENT];
          Elf32_Half     e_type;
          Elf32_Half     e_machine;
          Elf32_Word     e_version;
          Elf32_Addr     e_entry;
          Elf32_Off      e_phoff;
          Elf32_Off      e_shoff;
          Elf32_Word     e_flags;
          Elf32_Half     e_ehsize;
          Elf32_Half     e_phentsize;
          Elf32_Half     e_phnum;
          Elf32_Half     e_shentsize;
          Elf32_Half     e_shnum;
          Elf32_Half     e_shstrndx;
 } Elf32_Ehdr;
```

Нас будут интересовать следующие данные:
e_shnum - количество записей в Section Header Table (SHT далее).
e_shoff - смещение SHT от начала файла.
e_shentsize - размер записи section header в SHT.
e_shstrndx - индекс в SHT отвечающий за section name string table (strtab).

Типы и размеры данных используемых в ELF файле (источник 4 страница 16):

Figure 1-2. 32-Bit Data Types

Name	Size	Alignment	Purpose
Elf32_Addr	4	4	Unsigned program address
Elf32_Half	2	2	Unsigned medium integer
Elf32_Off	4	4	Unsigned file offset
Elf32_Sword	4	4	Signed large integer
Elf32_Word	4	4	Unsigned large integer
unsigned char	1	1	Unsigned small integer

Section Header Table содержит заголовки секций. Их структура (источник 4 страница 24):

Figure 1-8. Section Header

```
typedef struct {
          Elf32_Word   sh_name;
          Elf32_Word   sh_type;
          Elf32_Word   sh_flags;
          Elf32_Addr   sh_addr;
          Elf32_Off    sh_offset;
          Elf32_Word   sh_size;
          Elf32_Word   sh_link;
          Elf32_Word   sh_info;
          Elf32_Word   sh_addralign;
          Elf32_Word   sh_entsize;
} Elf32_Shdr;
```

Из них мы будем использовать:
sh_offset - смещение от начала файла до начала секции.
sh_name - индекс в section header string table с которого начинается название секции.
sh_size - размер секции.
sh_addr - индекс первого байта секции, если секция будет исполняться (отображаться в области памяти процесса).

Symbol Table section содержит информацию (таблицу символов), необходимую для определения местоположения и перемещения символических определений и ссылок программы.

Секция .symtab содержит массив следующих структур (источник 4 стр. 32):

Figure 1-15. Symbol Table Entry

```
typedef struct {
          Elf32_Word    st_name;
          Elf32_Addr    st_value;
          Elf32_Word    st_size;
          unsigned char st_info;
          unsigned char st_other;
          Elf32_Half    st_shndx;
} Elf32_Sym;
```

st_name	This member holds an index into the object file's symbol string table, which holds the character representations of the symbol names.
st_value	This member gives the value of the associated symbol. Depending on the context, this may be an absolute value, an address, and so on; details appear below.
st_size	Many symbols have associated sizes. For example, a data object's size is the number of bytes contained in the object. This member holds 0 if the symbol has no size or an unknown size.
st_info	This member specifies the symbol's type and binding attributes. A list of the values and meanings appears below. The following code shows how to manipulate the values.
st_other	This member currently holds 0 and has no defined meaning.
st_shndx	Every symbol table entry is "defined" in relation to some section; this member holds the relevant section header table index. As Figure 1-7 and the related text describe, some section indexes indicate special meanings.

Секция .text содержит информацию о исполняемых инструкциях программы. Размер каждой команды 4 байта. Реализован разбор команд из наборов RV32I, RV32M, RV32A. Команды в них принадлежат одному из 6 следующих типов (источник 1 страница 30):

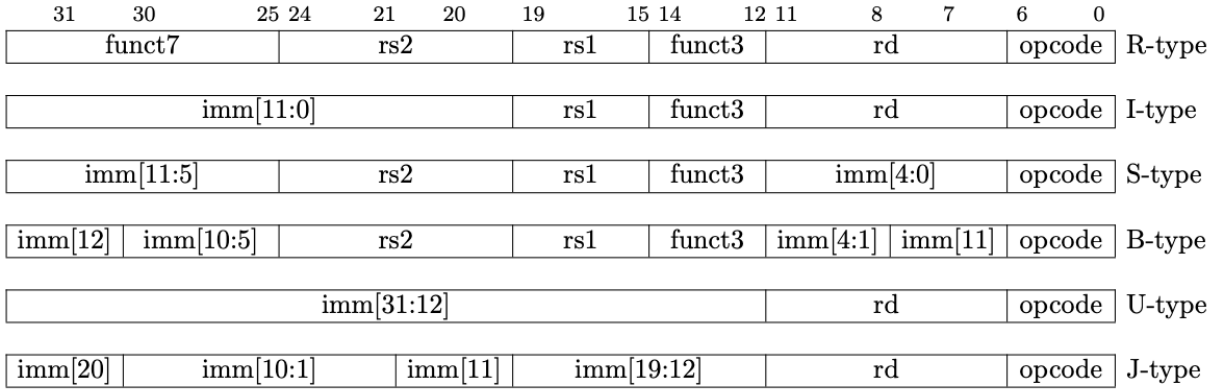

Opcode, funct3, funct7 используются для определения типа команды. rd - регистр назначения, rs1, rs2 - регистры источника. Imm определяют смещение / адрес назначения.

Информация о отображении регистров (источник 2 страница 155):

Register	ABI Name	Description	Saver
x0	zero	Hard-wired zero	—
x1	ra	Return address	Caller
x2	sp	Stack pointer	Callee
x3	gp	Global pointer	—
x4	tp	Thread pointer	—
x5	t0	Temporary/alternate link register	Caller
x6–7	t1–2	Temporaries	Caller
x8	s0/fp	Saved register/frame pointer	Callee
x9	s1	Saved register	Callee
x10–11	a0–1	Function arguments/return values	Caller
x12–17	a2–7	Function arguments	Caller
x18–27	s2–11	Saved registers	Callee
x28–31	t3–6	Temporaries	Caller
f0–7	ft0–7	FP temporaries	Caller
f8–9	fs0–1	FP saved registers	Callee
f10–11	fa0–1	FP arguments/return values	Caller
f12–17	fa2–7	FP arguments	Caller
f18–27	fs2–11	FP saved registers	Callee
f28–31	ft8–11	FP temporaries	Caller

Информация о определении значения Imm (источник 1 страница 31):

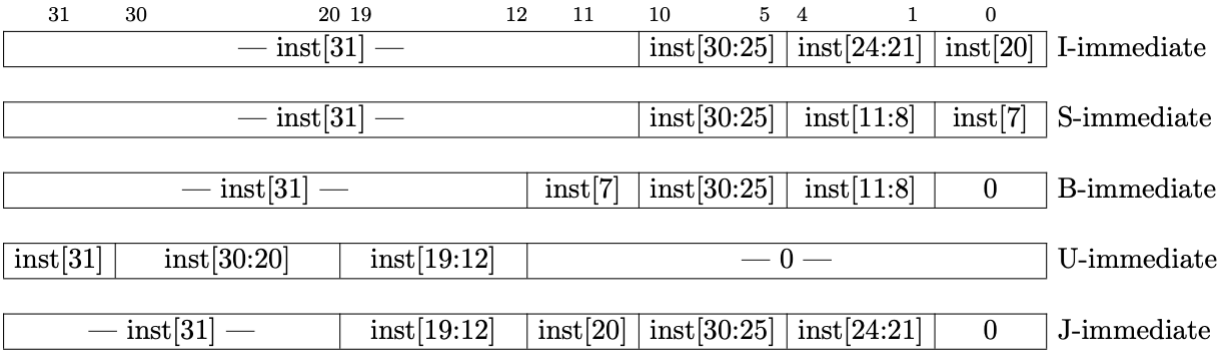

Более наглядный пример для определения J-Imm:

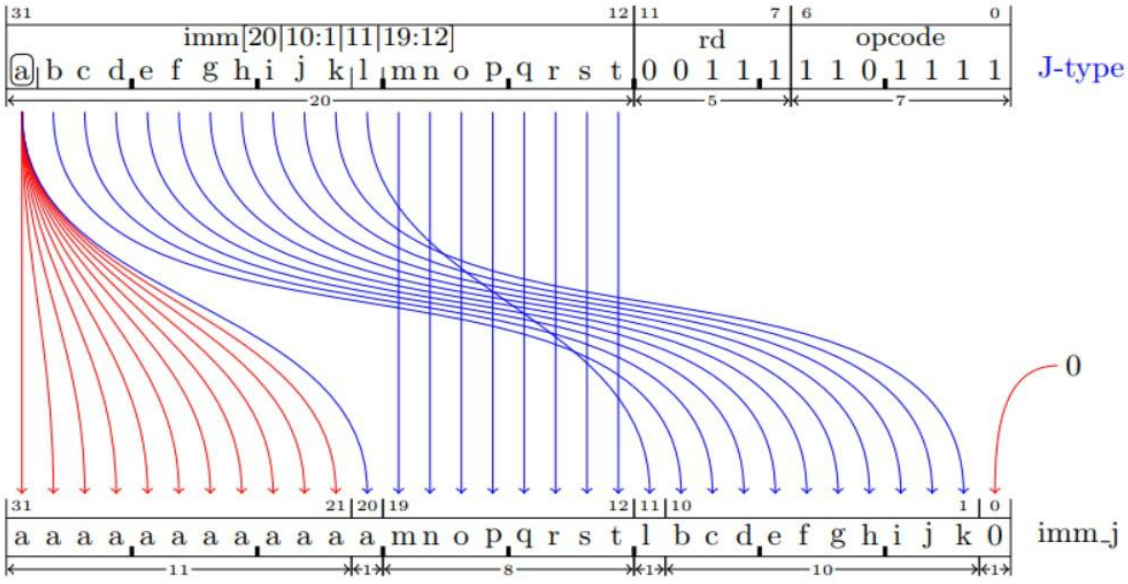

Figure 5.7: Decoding a J-type instruction.

Реализованны команды (источник 2 страница 148):

RV32I Base Instruction Set

imm[31:12]				rd	0110111	LUI
imm[31:12]				rd	0010111	AUIPC
imm[20|10:1|11|19:12]				rd	1101111	JAL
imm[11:0]		rs1	000	rd	1100111	JALR
imm[12|10:5]	rs2	rs1	000	imm[4:1|11]	1100011	BEQ
imm[12|10:5]	rs2	rs1	001	imm[4:1|11]	1100011	BNE
imm[12|10:5]	rs2	rs1	100	imm[4:1|11]	1100011	BLT
imm[12|10:5]	rs2	rs1	101	imm[4:1|11]	1100011	BGE
imm[12|10:5]	rs2	rs1	110	imm[4:1|11]	1100011	BLTU
imm[12|10:5]	rs2	rs1	111	imm[4:1|11]	1100011	BGEU
imm[11:0]		rs1	000	rd	0000011	LB
imm[11:0]		rs1	001	rd	0000011	LH
imm[11:0]		rs1	010	rd	0000011	LW
imm[11:0]		rs1	100	rd	0000011	LBU
imm[11:0]		rs1	101	rd	0000011	LHU
imm[11:5]	rs2	rs1	000	imm[4:0]	0100011	SB
imm[11:5]	rs2	rs1	001	imm[4:0]	0100011	SH
imm[11:5]	rs2	rs1	010	imm[4:0]	0100011	SW
imm[11:0]		rs1	000	rd	0010011	ADDI
imm[11:0]		rs1	010	rd	0010011	SLTI
imm[11:0]		rs1	011	rd	0010011	SLTIU
imm[11:0]		rs1	100	rd	0010011	XORI
imm[11:0]		rs1	110	rd	0010011	ORI
imm[11:0]		rs1	111	rd	0010011	ANDI
0000000	shamt	rs1	001	rd	0010011	SLLI
0000000	shamt	rs1	101	rd	0010011	SRLI
0100000	shamt	rs1	101	rd	0010011	SRAI
0000000	rs2	rs1	000	rd	0110011	ADD
0100000	rs2	rs1	000	rd	0110011	SUB
0000000	rs2	rs1	001	rd	0110011	SLL
0000000	rs2	rs1	010	rd	0110011	SLT
0000000	rs2	rs1	011	rd	0110011	SLTU
0000000	rs2	rs1	100	rd	0110011	XOR
0000000	rs2	rs1	101	rd	0110011	SRL
0100000	rs2	rs1	101	rd	0110011	SRA
0000000	rs2	rs1	110	rd	0110011	OR
0000000	rs2	rs1	111	rd	0110011	AND
fm | pred | succ		rs1	000	rd	0001111	FENCE
000000000000		00000	000	00000	1110011	ECALL
000000000001		00000	000	00000	1110011	EBREAK

RV32M Standard Extension

0000001	rs2	rs1	000	rd	0110011	MUL
0000001	rs2	rs1	001	rd	0110011	MULH
0000001	rs2	rs1	010	rd	0110011	MULHSU
0000001	rs2	rs1	011	rd	0110011	MULHU
0000001	rs2	rs1	100	rd	0110011	DIV
0000001	rs2	rs1	101	rd	0110011	DIVU
0000001	rs2	rs1	110	rd	0110011	REM
0000001	rs2	rs1	111	rd	0110011	REMU

RV32A Standard Extension

00010	aq	rl	00000	rs1	010	rd	0101111	LR.W
00011	aq	rl	rs2	rs1	010	rd	0101111	SC.W
00001	aq	rl	rs2	rs1	010	rd	0101111	AMOSWAP.W
00000	aq	rl	rs2	rs1	010	rd	0101111	AMOADD.W
00100	aq	rl	rs2	rs1	010	rd	0101111	AMOXOR.W
01100	aq	rl	rs2	rs1	010	rd	0101111	AMOAND.W
01000	aq	rl	rs2	rs1	010	rd	0101111	AMOOR.W
10000	aq	rl	rs2	rs1	010	rd	0101111	AMOMIN.W
10100	aq	rl	rs2	rs1	010	rd	0101111	AMOMAX.W
11000	aq	rl	rs2	rs1	010	rd	0101111	AMOMINU.W
11100	aq	rl	rs2	rs1	010	rd	0101111	AMOMAXU.W

Расширение Zifencei (источник 1 страница 46) включает в себя инструкцию fence.i:

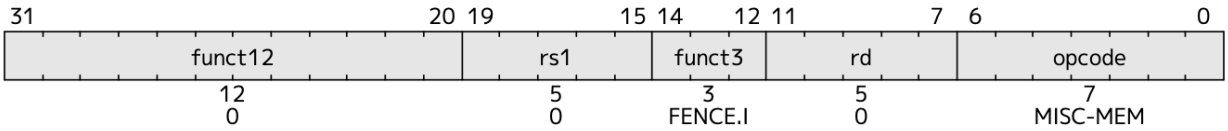

Расширение Zihintpause (источник 1 страница 52) включает в себя специальное действие, если части fence инструкции принимают следующие значения: pred = W, succ = 0, fm = 0, rd = x0, и rs1 = x0.

Детали реализации:

Весь файл записывается в vector<int>.
В начале парсится header (parse_header.cpp).

```
3  void read_header(std::vector<int>& file, Header& header) {
4      int ptr = 0;
5      for (int i = 0; i < EI_NIDENT; i++) {
6          header.e_ident[i] = file[ptr++];
7      }
8      header.e_type = read_half(file, ptr);
9      header.e_machine = read_half(file, ptr);
10     header.e_version = read_whole(file, ptr);
11     header.e_entry = read_whole(file, ptr);
12     header.e_phoff = read_whole(file, ptr);
13     header.e_shoff = read_whole(file, ptr);
14     header.e_flags = read_whole(file, ptr);
15     header.e_ehsize = read_half(file, ptr);
16     header.e_phentsize = read_half(file, ptr);
17     header.e_phnum = read_half(file, ptr);
18     header.e_shentsize = read_half(file, ptr);
19     header.e_shnum = read_half(file, ptr);
20     header.e_shstrndx = read_half(file, ptr);
21 }
```

Здесь и далее для чтения команд/данных из нескольких байтов используются функции read_half и read_whole для данных порциями по 2 и 4 байта соответственно.

```
23  Elf32_Half read_half(std::vector<int>& file, int& ptr) {
24      Elf32_Half read_el = 0;
25      for(int i = 1; i >= 0; i--) {
26          read_el *= 16*16;
27          read_el += file[ptr + i];
28      }
29      ptr += 2;
30      return read_el;
31  }
32
33  uint32_t read_whole(std::vector<int>& file, int& ptr) {
34      uint32_t read_el = 0;
35      for(int i = 3; i >= 0; i--) {
36          read_el *= 16*16;
37          read_el += file[ptr + i];
38      }
39      ptr += 4;
40      return read_el;
41  }
```

Формат хранения данных littel endian из-за чего перед прочтением следующего байта уже имеющаяся часть сдвигается на 8 бит (умножется на 16^2).

Далее парсится Section Header Table (parse_sh.cpp). Информация собирается в структуры Elf32_Shdr (источник 4 страница 24) и помещается в массив.

```
3   void read_sh(std::vector<int>& file, Elf32_Shdr* sh, Header& header) {
4       for (int i = 0; i < header.e_shnum; i++) {
5           int ptr = header.e_shoff + i * header.e_shentsize;
6           Elf32_Shdr tmp;
7           tmp.sh_name = read_whole(file, ptr);
8           tmp.sh_type = read_whole(file, ptr);
9           tmp.sh_flags = read_whole(file, ptr);
10          tmp.sh_addr = read_whole(file, ptr);
11          tmp.sh_offset = read_whole(file, ptr);
12          tmp.sh_size = read_whole(file, ptr);
13          tmp.sh_link = read_whole(file, ptr);
14          tmp.sh_info = read_whole(file, ptr);
15          tmp.sh_addralign = read_whole(file, ptr);
16          tmp.sh_entsize = read_whole(file, ptr);
17          sh[i] = (tmp);
18      }
19  }
```

Так как имена секций хранятся в strtab, далее записываем имена секций.

```
27  void read_real_names(std::vector<int>& file, std::vector<std::vector<char>>& sh_names, Header& header, Elf32_Shdr* sh) {
28      int strtab_idx = sh[header.e_shstrndx].sh_offset;
29      for(int i = 0; i < header.e_shnum; i++) {
30          std::vector<char> tek_name;
31          int j = 0;
32          while(file[strtab_idx + sh[i].sh_name + j]) {
33              tek_name.push_back(file[strtab_idx + sh[i].sh_name + j]);
34              j++;
35          }
36          sh_names[i] = tek_name;
37          //ar_copy(sh_names, tek_name, i);
38      }
39  }
```

Далее рассмотрим разбор symtab, данные из него потребуется для корретного вывода text.

```
3   void parse_symtab(std::vector<int>& file, Elf32_Shdr* sh, std::vector<std::vector<char>>& sh_names,
4       int strtab_idx = find_strtab(sh_names, header);
5       if (strtab_idx == -1) {
6           return;
7       }
8       int names_start_ptr = sh[strtab_idx].sh_offset;
9       for (int i = 0; i < header.e_shnum; i++) {
10          if (is_symtab(sh_names[i])) {
11              int sym_num = sh[i].sh_size / SYMTAB_SIZE;
12              Elf32_Sym* symtab_header = new Elf32_Sym[sym_num];
13              read_symtab_header(file, symtab_header, sh[i].sh_offset, sym_num);
14              final_print_symtab(file, symtab_header, sym_num, names_start_ptr, fp);
15              delete[] symtab_header;
16          }
17      }
18  }
```

Ищем strtab (просто потому что можем) далее определяем кол-во записей в strtab. SYMTAB посчитали как сумму равзмеров всех переменных в Elf32_Sym (скрин был приложен выше).

```
50  void final_print_symtab(std::vector<int>& file, Elf32_Sym* symtab_header, int sym_num, int names_start_ptr, FILE *fp) {
51      fprintf(fp, "\n.symtab\n");
52      fprintf(fp, "\nSymbol Value              Size Type     Bind     Vis       Index Name\n");
53      for(int i = 0; i < sym_num; i++) {
54          std::string type = symtab_type(symtab_header, i);
55          std::string bind = symtab_bind(symtab_header, i);
56          std::string vis = symtab_vis(symtab_header, i);
57          std::string idx = symtab_index(symtab_header, i);
58          std::vector<char> name;
59          symtab_name(file, names_start_ptr, symtab_header, i, name);
60          std::string out_str (name.begin(), name.end());
61          if (out_str.size()) {
62              fprintf(fp, "[%4i] 0x%-15X %5i %-8s %-8s %-8s %6s %s\n", i, symtab_header[i].st_value, symtab_header[i].st_size,
63                  type.c_str(), bind.c_str(), vis.c_str(), idx.c_str(), out_str.c_str());
64          } else {
65              fprintf(fp, "[%4i] 0x%-15X %5i %-8s %-8s %-8s %6s %s\n", i, symtab_header[i].st_value, symtab_header[i].st_size,
66                  type.c_str(), bind.c_str(), vis.c_str(), idx.c_str(), "");
67          }
68      }
69  }
```

Информации о том, как отображать type, bind, vis и idx взята из (источки 3 страница 359, 357, 360, 307 соответственно). Имена считываем из strtab начиная с индекса, хранимого в переменной st_name каждой структуры до нуля.

Разбор text (скриншоты не приложены в силу большого объема кода): Для корректного отображения меток необходимо иметь информацию о блоках кода, описанных в symtab, а также знать метки, создаваемые инструкциями J и B типа. В начале перебираем все инструкции и, если они принадлежат B или J типу, а также адрес назначения еще не известен, создаем новую метку L<x> и сохраняем ее в вектор Ls для будующего использования (create_labes и функции, вызываемые ею).

```
3  void parse_text(std::vector<int>& file, Elf32_Shdr* sh, std::vector<std::vector<char>>& sh_names, Header& header, FILE* fp) {
4      int symtab_idx = find_symtab(sh_names, header.e_shnum);
5      int names_start_ptr = sh[find_strtab(sh_names, header)].sh_offset;
6      int sym_num = sh[symtab_idx].sh_size / SYMTAB_SIZE;
7
8      Elf32_Sym* symtab_header = new Elf32_Sym[sym_num];
9      read_symtab_header(file, symtab_header, sh[symtab_idx].sh_offset, sym_num);
10
11     std::vector<unsigned int> Ls;
12
13     for (int i = 0; i < header.e_shnum; i++) {
14         if (is_text(sh_names[i])) {
15             create_labels(file, sh, i, symtab_header, names_start_ptr, sym_num, Ls);
16         }
17     }
18
19     for (int i = 0; i < header.e_shnum; i++) {
20         if (is_text(sh_names[i])) {
21             final_print_text(file, sh, i, fp, symtab_header, names_start_ptr, sym_num, Ls);
22         }
23     }
24
25     delete[] symtab_header;
26 }
```

Имея данные о всех метках, создаваемых в процессе исполнения программы и данных нам в секции symtab можно выводить инструкции (final_print_text и функции, вызываемые ею). На основе последних семи битов инструкции и, при необходимости, 13-15 битах определяем инструкцию и тип, к которому она принадлежит.

Информация, необходимая для вывода интрукций была приложена выше.

Комментарии относительно авторского понимания RV32A и расширений:

Атомарные операции имеют два дополнительных поля aq, rl отвечающие за доступ инструкции к памяти (источник 1 страница 64). При выводе инструкции, если биты, отвечающие за aq и/или rl равны 1, к имена команды добавляется .aq/.rl/.aqrl.

Расширение Zihintpause: fence с пустым полем источника и направления ничего не делает и используется для эффективного простаивания процессора и/или выравнивания других инструкций. Вывод ничем не отличается от обычной fence инструкции кроме отсутствия ','.

Расширение Zifencei: Вывод fence.i инструкции совпадет с обычными I-type инструкциями. (я тут не очень понял)

Источники:

1: https://github.com/riscv/riscv-isa-manual/releases/download/riscv-isa-release-056b6ff-2023-10-02/unpriv-isa-asciidoc.pdf

2: https://refspecs.linuxfoundation.org/elf/elf.pdf

3: https://docs.oracle.com/cd/E26502_01/pdf/E26507.pdf

4: https://riscv.org/wp-content/uploads/2019/12/riscv-spec-20191213.pdf